

BULANIK MANTIK VE YAPAY SİNİR AĞLARINA GİRİŞ

HAFTA – 12

ÖĞRENME TÜRLERİ

DR. ÖĞR. ÜYESİ M. FATİH ADAK

İÇERİK

- Öğrenme Türleri
- Geri dönüşümlü ağlar
 - Tam geri dönüşümlü ağlar
 - Kısmi geri dönüşümlü ağlar
- Destekli öğrenme Elman ağı
 - Elman ağında eğitim
- Desteksiz öğrenme Hopfield ağı
 - Hebb öğrenme kuralı
 - Hopfield ağı çeşitleri
- Takviyeli öğrenme LVQ Ağı
 - LVQ ağı öğrenme modeli
 - Avantaj ve dezavantajları
 - LVQ ağ çeşitleri



ÖĞRENME TÜRLERİ

- Destekli Öğrenme
 - Doğrusal Ağlar
 - İleri Beslemeli Çok Katmanlı Ağlar (BP öğrenme modeli)
 - Geri Dönüşümlü Ağlar
 - Elman Ağı
- Desteksiz Öğrenme
 - Tekrar Beslemeli Ağlar
 - Hopfield Ağı
- Takviyeli Öğrenme
 - LVQ Ağı


GERİ DÖNÜŞÜMLÜ AĞLAR

- Tam geri dönüşümlü ağlar
 - Düğümlerden ileri ve geriye doğru bağlantıları olan ağlardır.
 - Bu ağırlıkların hepsi bilgiyi temsil eder ve güncellenirler.
- Kısmi geri dönüşümlü ağlar
 - Ağın düğümleri dışında bir de içerik elemanları vardır.
 - Aslında ileri beslemeli ağlardır.
 - İleri yöndeki ağırlıklar güncellenir.
 - Geri dönüşüm içerik elemanları ile yapılır fakat bunlar güncellenmezler.

TAM GERİ DÖNÜŞÜMLÜ AĞLAR



KISMİ GERİ DÖNÜŞÜMLÜ AĞLAR




KİSMİ GERİ DÖNÜŞÜMLÜ AĞLAR

- İçerik elemanları gizli katmandaki düğümlerin geçmiş bilgilerini hatırlamak için kullanılırlar.
- Ağın çıktısı hem önceki bilgilere hem de ağın o andaki bilgisine bağlı olarak oluşturulmaktadır.
- Kısa süreli hafıza problemlerinde etkili kullanılabilirler.
- Labirentten çıkma örneği

ELMAN AĞI

- İçerik eleman sayısının gizli katmandaki nöron sayısına eşit olduğu ağlardır.
- Elman ağı kısmi geri dönüşümlü ağıdır. Nedeni ara katmandan içerik katmanına bağlı olan ağırlıklar **güncellenmez**.



DESTEKLİ ÖĞRENME ELMAN AĞI

- Girdi Katmanı

Dış dünyadan bilgileri alır ve ara katmanlara iletirler. Diğer ağlarda olduğu gibi Elman ağına da girdi elemanlarının bilgi işleme özellikleri yoktur.

- Gizli Katman

Bu katmanda hem doğrusal hem de doğrusal olmayan aktivasyon fonksiyonlarına sahip olabilirler.

- İçerik Katmanı

İçerik elemanları ara katman elemanlarının önceki çıkış değerlerini hatırlamak için (kısa süreli hafıza) kullanılırlar.

- Çıktı Katmanı

Ağın çıktısının dış dünyaya iletildiği katmandır. Çıktı katmanından içerik elemanlarına bir bağlantı veya bilgi akışı yoktur.

ELMAN AĞINDA EĞİTİM

- Her hangi bir iterasyonda ağa hem o anki girdi değerleri hem de bir önceki iterasyondaki girdi değerleri verilir.
- Buradan sonrası ileri beslemeli çok katmanlı ağlar ile aynıdır.
- İleri beslemeden sonra ara katman çıkışları içerik elemanlarına gönderilir ve bir sonraki iterasyon için saklanır.
- İlk iterasyonda içerik elemanlarının değeri olmadığı için genelde ara katmanın alabileceği maksimum değerin yarısı başlangıç değeri olarak kabul edilir.

DESTEKSİZ ÖĞRENME HOPFIELD AĞLARI

- Bu ağlarda tekrar beslemeli bir yapıya sahiptir. Bu özellik onu diğer YSA'lerden ayırmaktadır.
- Bu yetenek girdi değerleri ağa verildiğinde ağ bir başlangıç enerjisine sahip olacak ve girdiyi daha önce öğrendiği bir örüntüye yaklaştıracaktır.

$$n_i(t+1) = \Theta\left(\sum_j w_{ij}n_j(t) - \mu_i\right)$$

- Θ adım fonksiyonudur. Hopfield ağları ikili tabanda çıktı verir. Girdi olarak -1 ile 1 arasında değer alabilir.

$$\text{sgn}(x) = \begin{cases} 1 & \text{if } x \geq 0 \\ -1 & \text{if } x < 0 \end{cases} \quad S_i = \text{sgn}\left(\sum_j w_{ij}S_j\right)$$

HOPFIELD AĞLARI AĞIRLIKLARIN GÜNCELLENMESİ

- İki farklı yol ile yapılabilir.
 - Senkron
 - Her iterasyonda bütün birimleri aynı anda güncelle
 - Asenkron
 - Her bir birimi ayrı ayrı güncelle
 - Aynı zaman diliminde bir birim rastgele seçilir ve güncellenir.
 - Olasılığa dayalı olarak her birimin kendisini güncellemesine olanak tanınır.

HOPFIELD AĞLARI

- Tek katmanlı ve geri dönüşümlü ağlardır.
- Bütün nöronlar hem girdi hem de çıktı nöronudur.
- Nöronlar açık (+1) ya da kapalı (-1) mantığına göre çalışır.
- Aktivasyon fonksiyonu süreksiz formda
 - Eşik fonksiyonu
- Aktivasyon fonksiyonu sürekli formda
 - Sigmoid ve tanjant hiperbolik fonksiyonları
- Ağırlıklar bir enerji fonksiyonu olarak saklanmaktadır.

HEBB ÖĞRENME KURALI

- Bu öğrenme kuralına göre ağırlığın bağlı olduğu iki nöronun işareti aynı ise ağırlık arttırılır, aksi takdirde azaltılır.
- Ağırlığın gücü her ikisi açık veya her ikisi kapalı olduğunda artacak aksi halde azalacaktır.

$$w_{ij} = a_i a_j$$

- Ağın aktivasyon deseni depolanmış bir desene yakınsa, o desene doğru gitmeye çalışacaktır.
- Ağdaki hiçbir nöronun kendine bağlantısı yoktur.
- $w_{ij} = w_{ji}$

HEBB ÖĞRENME KURALI

- Herhangi bir nöron için giriş değeri hesaplanır.

$$g_i(t) = \sum_{j \neq i}^n w_{ji} \zeta_j(t-1) - \Theta_i$$

- Bu giriş değeri aktivasyon fonksiyonuna verilerek çıkış değeri hesaplanır.

$$\zeta_i(t) = \text{sgn}[g_i(t)]$$
$$\zeta_i(t) = \text{sigmoid}[g_i(t)]$$

HEBB ÖĞRENME KURALI

- $\zeta_i(t)$ i. nöronun t anındaki çıkışı
- $\zeta_j(t)$ j. nöronun t anındaki çıkışı
- Bunlara göre Enerji fonksiyonu şu şekilde hesaplanır.


$$E(t) = -\frac{1}{2} \sum_i \sum_{j \neq i} w_{ij} \zeta_i(t) \zeta_j(t) + \sum_i \zeta_i(t) \theta_i$$

- Eğer enerji fonksiyon değeri sabit ise veya daha fazla düşmüyorsa eğitim son bulur. Aksi halde eğitim devam eder.

HOPFIELD AĞLARI EĞİTİM


- Ağın öğrenmesinde Hebb kuralı uygulanır.
- Nöronlar kararlı bir yapıya ulaşıncaya kadar çalıştırılır.
- Nöronların son durumları okunarak çıktı elde edilir.

Input: (1 0 1 -1 -1)



Output: (1 -1 1 -1 -1)

HOPFIELD AĞLARI ÖRÜNTÜ



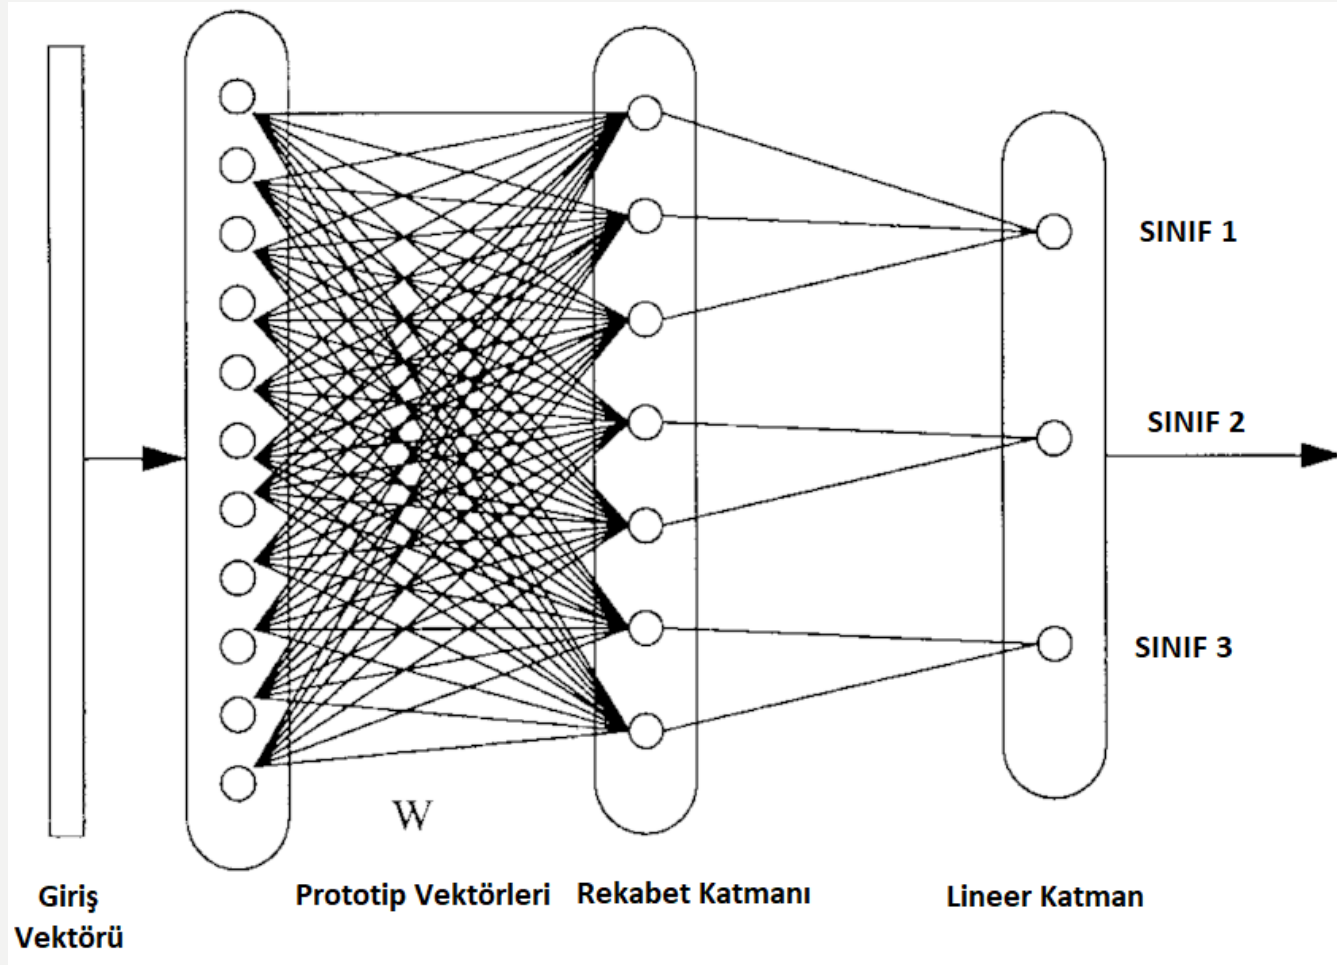
HOPFIELD AĞI ÇEŞİTLERİ

- Kesikli Hopfield Ağı
 - Çağrışimli bellek olarak kullanılır.
 - Görüntü tanıma ve onarma (kullanıldığı örnekler)
 - Sgn aktivasyon fonksiyonunu kullanır.
- Sürekli Hopfield Ağı
 - Optimizasyon problemlerinde daha çok kullanılır.
 - Gezgin satıcı problemi (kullanıldığı örnekler)
 - Aktivasyon fonksiyonu olarak türevi alınabilecek bir fonksiyon (Sigmoid gibi) olmalıdır.

TAKVİYELİ ÖĞRENME LVQ AĞLARI

- Model Kohonen tarafından 1984 yılında geliştirilmiştir.
- Çıkış noktası, n boyutlu bir vektörü elde bulunan hazır vektör seti ile ifade edebilmektir.
- Vektörün belirli sayıda vektör ile gösterimi amaçlanmaktadır.
- Elde bulunan hazır vektör setine referans vektör seti denilmektedir.
- LVQ ağı da girdi vektörlerinin üyesi olabilecekleri vektör sınıflarını belirlemeye çalışmaktadır.
- LVQ ağında öğrenme hızı oldukça yüksektir.

LVQ AĞLARI



LVQ AĞLARI

- LVQ ağırları genellikle sınıflandırma problemlerinin çözümünde kullanılmaktadırlar.
- Çıktının 1 olması girdinin ilgili çıktının temsil ettiği sınıfa ait olduğunu göstermektedir.
- Eğitim sırasında girdilerin sınıflara ayrılması en yakın komşu kuralına göre gerçekleşmektedir.
- Girdileri doğru bir şekilde eldeki vektörler ile temsil edebilmek için ağırlıklar değiştirilir.
- Bu ağda temel felsefe kazanan her şeyi alır ilkesidir.
- Sadece girdi vektörüne en yakın olan vektörün yani kazanan vektörün ağırlığı değiştirilir.

LVQ AĞLARI ÖĞRENME MODELİ

- Öğrenme ara katmandaki işlem elemanlarının birbirleri ile yarışma ilkesine dayanır.
- Temel mantık girdi vektörü ile hareket vektörü arasındaki öklid mesafesinin hesaplanmasıdır.

$$d = |A_i - X| = \sqrt{\sum_j (A_{ij} - X_j)^2}$$

- d: Girdi vektörü X ile referans vektörü A arasındaki mesafe
- j: Girdi vektörünün j. değeri

LVQ AĞLARI ÖĞRENME MODELİ

- Öğrenme sırasında, sadece girdi katmanını ilgili işlem birimine bağlayan bağlantıların ağırlık değerleri değiştirilir.
- Kohonen (ara) katmanda bir eleman yarışmayı kazandığında iki durum söz konusudur.
 - Kazanan vektör eğer girdi vektörü ile aynı sınıfta yer alıyorsa bu vektörün elemanları girdi vektörüne daha yakın olacak şekilde düzenlenirler. Böylelikle aynı örnek ağa tekrar gösterildiğinde yine aynı elemanın kazanması garanti altına alınmış olunur.
 - Diğer durumda ise referans vektörü ile girdi vektörü farklı sınıflarda oldukları için kazanan işlem elemanı yanlış sınıftadır ve bu vektörün değerleri girdi vektöründen uzaklaştırılır.

LVQ AĞLARI ÖĞRENME MODELİ


- Kazanan vektör evet sinyali alırsa referans vektörüne yaklaştırılır.

$$A_y = A_e + \lambda(X - A_e)$$

- Kazanan vektör hayır sinyalini alırsa referans vektöründen uzaklaştırılır.

$$A_y = A_e - \lambda(X - A_e)$$

LVQ AĞLARI ÖĞRENME MODELİ



LVQ AĞLARI AVANTAJ VE DEZAVANTAJLARI

- Ağın öğrenmesi temel çok katmanlı ağlara göre daha hızlı ve kolaydır. Doğrusal olmayan problemlerde kullanılabilir.
- Öğrenme katsayısının zamanında sıfır değerini almaması durumunda ağın öğrendiklerini unutması ve doğru ağırlık değerlerinden uzaklaşması söz konusudur.
- Bazı problemlerde sürekli olarak aynı referans vektörü kazanmaktadır ki bu istenen bir durum değildir.
- Sınıflandırma yapılırken iki sınıfın tam ortasında veya sınırlara çok yakın bulunan vektörlerin hangi sınıfa gireceği belirlenemeyebilir.

LVQ AĞ ÇEŞİTLERİ

- **LVQ2 Ağı**

Sınır değerlerindeki yanlış sınıflandırmayı önlemek için geliştirilmiştir.

Eğitim sırasında aynı anda 2 referans vektörünün ağırlıkları değiştirilmektedir.

- **Cezalandırma Mekanizmalı LVQ**

Aynı referans vektörünün sürekli kazanmasının önüne geçmek için ağ üzerinde sürekli olarak kazanan vektörler cezalandırılır.

- **LVQ-X Ağı**

Öğrenme hızını arttırmak için eğitim sırasında çoğunlukla iki ağırlık vektörünün ağırlıkları değiştirilir.

KAYNAKLAR

- Bishop, Christopher M. "Pattern recognition and machine learning, 2006." 60.1 (2012): 78-78.
- Shalev-Shwartz, S., & Ben-David, S. (2014). *Understanding machine learning: From theory to algorithms*. Cambridge university press.
- Blum, A. L., & Langley, P. (1997). Selection of relevant features and examples in machine learning. *Artificial intelligence*, 97(1-2), 245-271.
- Öztemel, E. (2003). *Yapay Sinir Ağları*. PapatyaYayincilik, İstanbul.
- Sağıroğlu, Ş., Beşdok, E., & Erler, M. (2003). *Mühendislikte yapay zeka uygulamaları- I: Yapay sinir ağları*. Ufuk Kitap Kirtasiye-Yayincılık.